

Лекция 5. Формальные языки. Регулярные языки и выражения.

1 Формальные языки

1.1 Определения и обозначения

Определение 1.1. Алфавит — конечное множество. По умолчанию обозначаем $\Sigma = \{a_1, a_2, \dots, a_n\}$.

Определение 1.2. Слово — конечная последовательность символов алфавита.

- $w[i]$ — i -й элемент слова w
- $|w|$ — количество букв в слове w
- $|w|_a$ — количество букв a в слове w
- ε — слово нулевой длины (пустое слово)
- w^n — слово, получаемое, если записать слово w ровно n раз подряд
- w^R — слово, получаемое, если записать слово w побуквенно в обратном порядке
- Σ^* — множество всех конечных слов над алфавитом Σ
- Языком над алфавитом Σ называют подмножество Σ^*

Операции для языков

- Конкатенация: $X \cdot Y = \{x \cdot y \mid x \in X, y \in Y\}$
- Возведение в степень: $X^n = \underbrace{X \cdot X \cdot \dots \cdot X}_n$

Пример 1.1. $X = \{a, ab\}$, $X^3 = \{aaa, aaab, aaba, aabab, abaa, abaab, ababa, ababab\}$

- Объединение: $X|Y = X + Y = X \cup Y$
- Итерация (звезда Клини): $X^* = \varepsilon + X + X^2 + \dots + X^n + \dots$

Пример 1.2. $\Sigma = \{0, 1\}$, Σ^* — счётное, 2^{Σ^*} — множество всех подмножеств Σ^* (несчётно)

Действительно, рассмотрим подмножество всех языков вида: 1 слово длины 1, 1 слово длины 2 ... Каждый такой язык — это подмножество Σ^* . Теперь рассмотрим отрезок $[0, 1]$ и будем в двоичной системе счисления записывать числа из этого отрезка:

```

0, 0 0 0 ... 0 ...
0, 1 0 1 ... 1 ...
⋮
0, 1 1 1 ... 0 ...

```

Разбиваем на блоки длины 1, 2, 3, ... Таким образом, получим взаимнооднозначное соответствие между словами и этими десятичными записями. Итого, мы построили некоторое подмножество языков, которое уже имеет мощность континуум, а значит, и всё множество языков несчётно.

2 Регулярные языки и выражения

Определение 2.1. Пусть задан алфавит Σ . Регулярные языки REG определяются индуктивно:

- $\emptyset \in REG$
- $\{\varepsilon\} \in REG$
- $\forall a \in \Sigma \quad \{a\} \in REG$
- $\forall X, Y \in REG \quad X \cdot Y \in REG$
- $\forall X, Y \in REG \quad X + Y \in REG$
- $\forall X \in REG \quad X^* \in REG$

Иначе говоря, REG — наименьшее по включению подмножество всех языков, которое содержит $\emptyset$ и ε , любое однобуквенное слово Σ , а также замкнутое относительно конкатенации, объединения и итерации.

Регулярные выражения

- $\emptyset$ — пустой язык
- a — язык, состоящий из одного единственного слова из одной единственной буквы a
- $X \cdot Y$ или XY — конкатенация
- X^* — итерация

Замечание 2.1. Рассмотрим некоторый фиксированный Σ — алфавит, $\Sigma = \{a, b\}$. Любому регулярному языку в Σ будет соответствовать слово в алфавите $\tilde{\Sigma} = \{\Sigma, (,), +, \cdot, *, \emptyset, \varepsilon\}$. Таким образом, регулярное выражение — слово в алфавите $\tilde{\Sigma}$.

Замечание 2.2. (Отличие декартового произведения от конкатенации). Рассмотрим языки: $L_1 = \{a, ab\}$ и $L_2 = \{b, bb\}$. Тогда

$$L_1 L_2 = \{ab, abb, abbb\}$$

$$L_1 \times L_2 = \{(a, b), (a, bb), (ab, b), (ab, bb)\}$$

Пример 2.1. a^* — регулярное выражение, задающее язык слов $\{\varepsilon, a, aa, \dots\}$

$$ab^* = \{a, ab, abb, abbb, \dots\}$$

$$(ab)^* = \{\varepsilon, ab, abab, ababab, \dots\}$$

$$ab^* + ba^* = \{a, b, ab, ba, abb, baa, abbb, baaa, \dots\}$$

Пример 2.2.

$$(a + b)^* = (a^* \cdot b)^* \cdot a^* = (a^* + b)^*$$

$$a + b = \{a, b\}$$

$$(a + b)^2 = \{aa, ab, ba, bb\}$$

$$(a + b)^{13} \ni abbababaababb$$

Утверждение. Не все языки регулярные.

Доказательство. • Счётное объединение конечных множеств конечно или счётно

- Счётное объединение счётных множеств счётно
- Множество всех слов Σ^* счётно
- Множество R_k регулярных языков, описываемых регулярными выражениями с ровно k операциями конечно для любого k
- Множество 2^{Σ^*} имеет мощность континуум

□

Детерминированный конечный автомат (ДКА)

Определение 2.2. ДКА — это набор $(\Sigma, Q, Q_f, \delta, q_0)$

Синтаксис:

- Σ — конечный алфавит, слова над которым обрабатывает ДКА
- Q — конечное множество состояний автомата
- Q_f — множество принимающих состояний: $Q_f \subseteq Q$
- δ — функция (таблица) переходов $\delta : \Sigma \times Q \rightarrow Q$
- q_0 — начальное состояние: $q_0 \in Q$

Семантика:

- Читает слово один раз слева направо.
- Если слово дочитано до конца, и ДКА находится в принимающем состоянии, то слова принято.
- Если слово не дочитано (переход не определён) или дочитано, но ДКА не в принимающем состоянии, то слово отвергнуто.

Замечание 2.3. Набором $(\Sigma, Q, Q_f, \delta, q_0)$ мы задаём функцию, которая принимает $w \in \Sigma^*$ и возвращает да/нет. Хотим на словах из заданного языка L получать да, если слово из L , и нет — иначе.

	a	b	
q ₁	q ₁	q ₂	
q ₂	q ₂	q ₁	


Зададим функцию на словах, а не на буквах:

δ^*	a	b	aa	ab	
q_1	q_2	q_1			

$$\delta^*(q_1, ab) = \delta(\delta(q_1, a), b)$$

Мы считаем, что слово w принимается, если $\delta^*(q_0, w) \in Q_f$.

Пример 2.3. (Пример ДКА)



Недетерминированный конечный автомат (НКА)

Определение 2.3. НКА — это набор $(\Sigma, Q, Q_f, \delta, q_0)$

Синтаксис:

- Σ — конечный алфавит, слова над которым обрабатывает НКА
- Q — конечное множество состояний автомата
- Q_f — множество принимающих состояний: $Q_f \subseteq Q$
- δ — функция переходов $\delta : \{\Sigma \cup \varepsilon\} \times Q \rightarrow 2^Q$
- q_0 — начальное состояние: $q_0 \in Q$

Семантика:

- НКА функция переходов неоднозначная.
- НКА принимает слово, если возможно достижение принимающего состояния при полном считывании этого слова.

3 Диаграмма Мура

- Каждому состоянию автомата соответствует вершина графа.
- Вершины соединены направленными дугами, помеченными символами алфавита. Они соответствуют функции δ .
- Начальное состояние обозначают «входящей стрелкой», а принимающее — двойной обводкой.